Métricas para clasificación

Métricas para clasificación binaria

- El error (entropía cruzada o MSE) nos permite saber cómo se ajustan las probabilidades del modelo pero no nos explica cuan bien clasifica el modelo.
- El Accuracy solo sirve como promedio de clasificación general del modelo.
- Veremos a continuación una serie de métricas que nos permitirán observar con más detalle este comportamiento.

Matriz de confusión (clasificación binaria)

- Una matriz de confusión permite visualizar el funcionamiento del modelo de clasificación.
- Las filas representan la etiqueta real de cada clase, mientras que las columnas representan la predicción del modelo entrenado.
- La diagonal principal representa el correcto funcionamiento del modelo. Fuera de la diagonal: errores.

```
AAPutils.plot_confusion_matrix(y_true, y_pred)
```

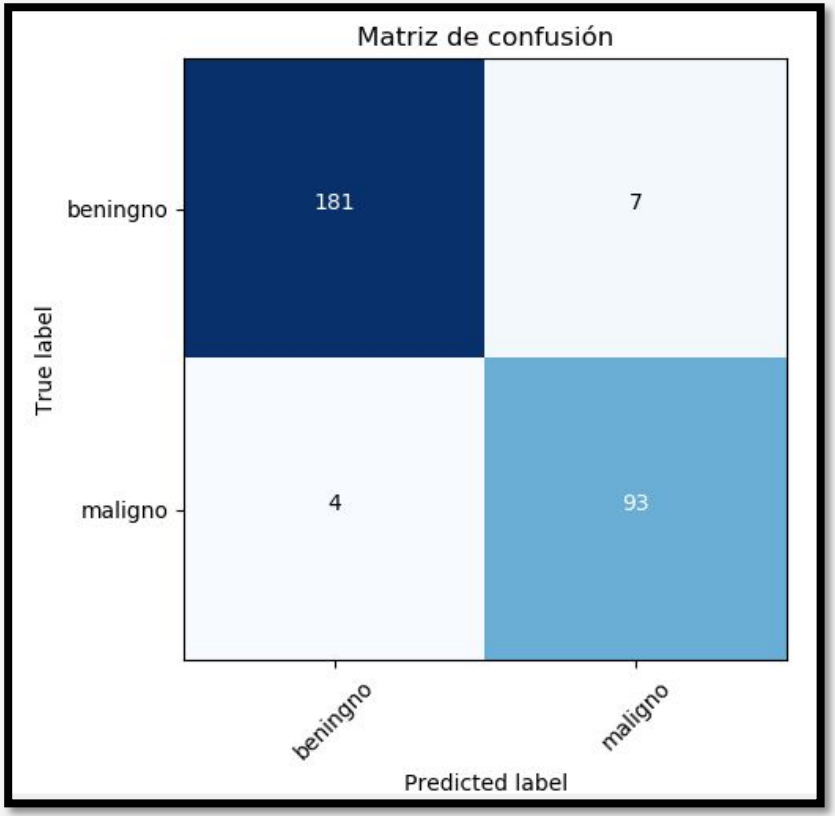

Matriz de confusión (clasificación multiclase)

Misma idea para multiclase.

Por ahora seguiremos con Clasificación Binaria.

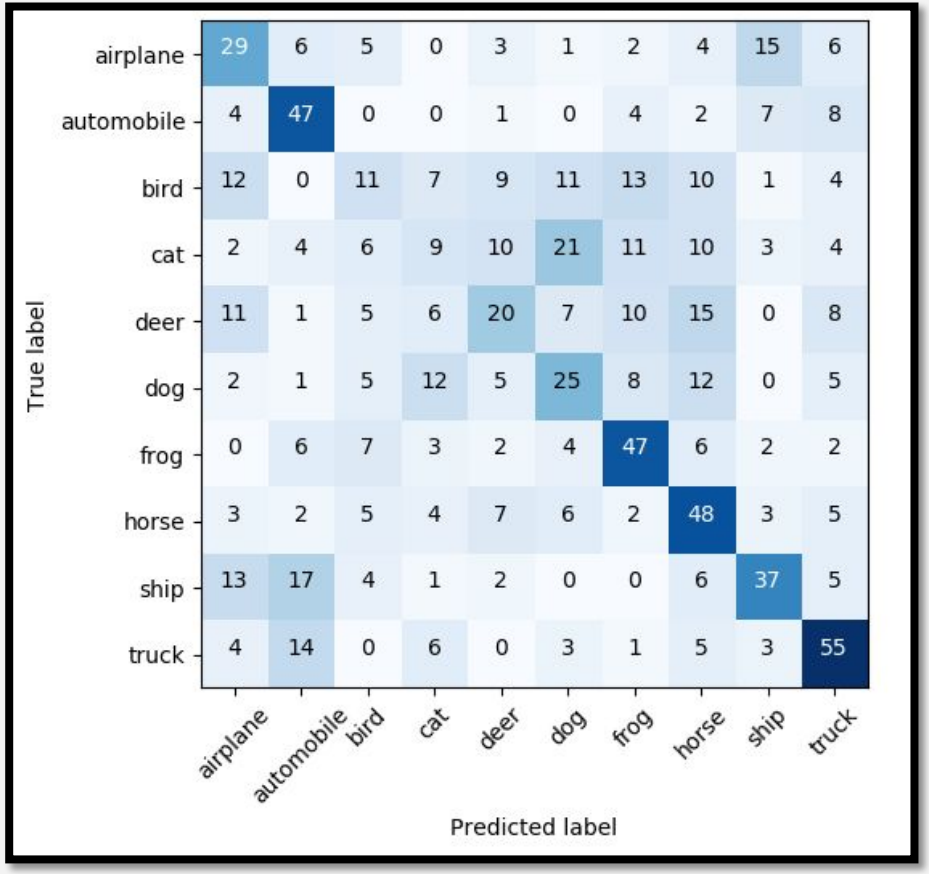

Matriz de confusión (clasificación binaria)

181 ejemplos eran Benignos y el modelo los clasificó como Benignos.

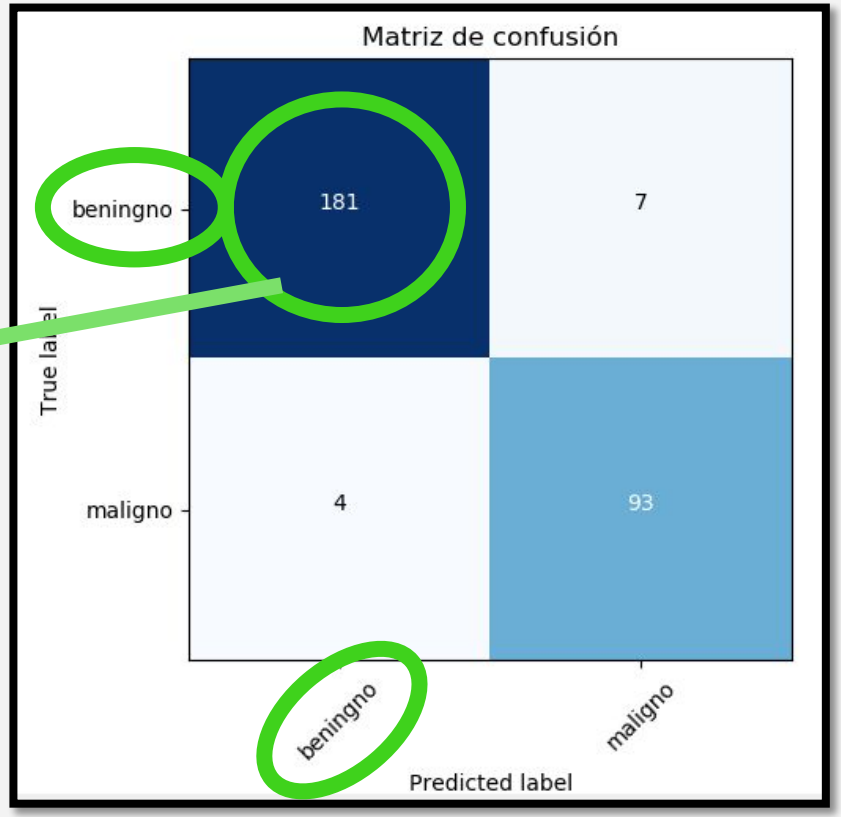

Matriz de confusión (clasificación binaria)

4 ejemplos eran Malignos y el modelo los clasificó como Benignos (Error).

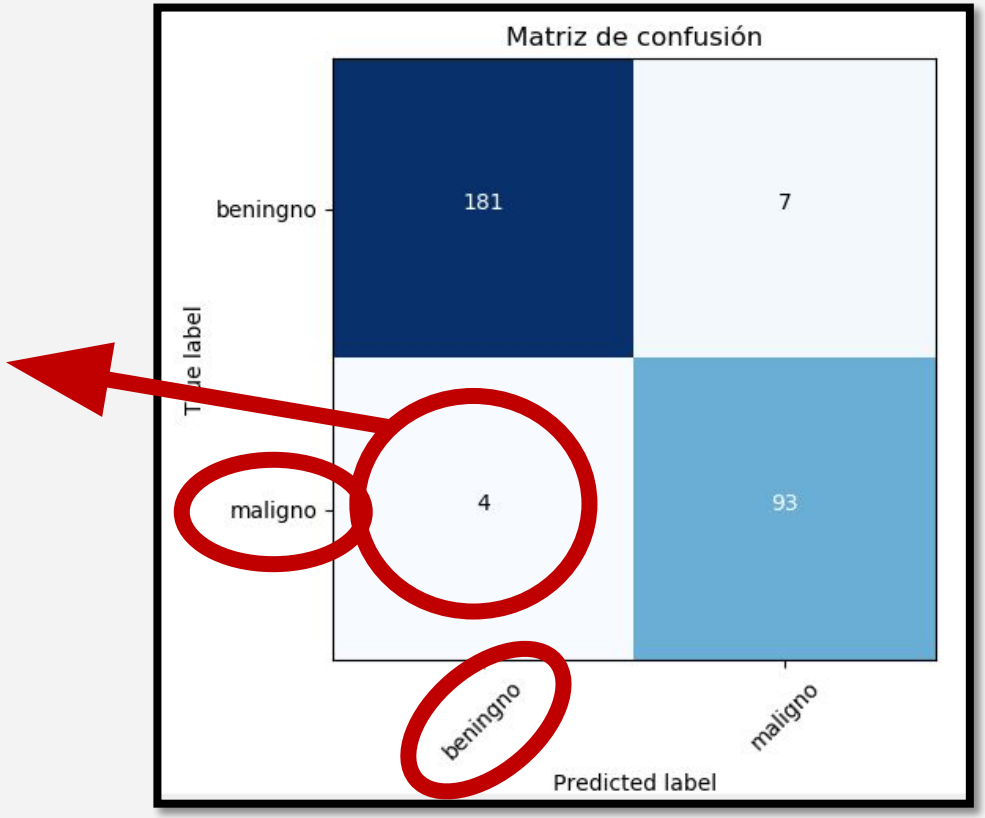

Métricas

True Negatives

Falses Positives

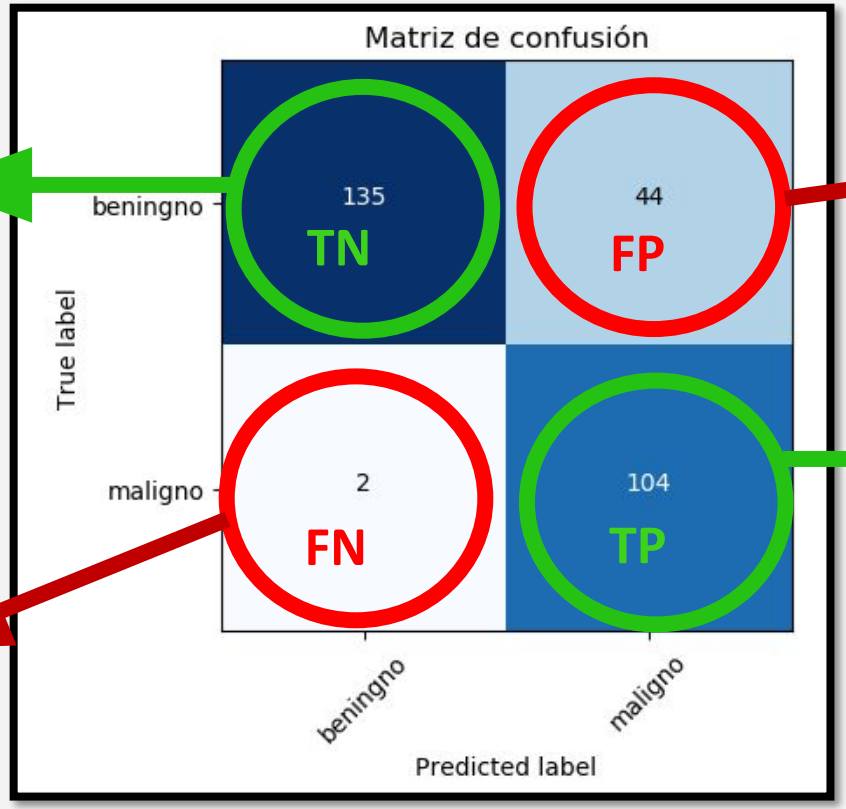

True Positives

Falses Negatives

Métricas - Accuracy

$$\textbf{Accuracy} = \frac{num\ predicc.\ correctas}{total\ predicciones} = \frac{TP + TN}{(TP+TN+FP+FN)}$$

$$\textbf{Acc} = \frac{1}{n}\sum_{i}^{n}(y\hat{}_i - y_i)$$

Acc = (104+135) / (104+135+44+2)= **0,84**

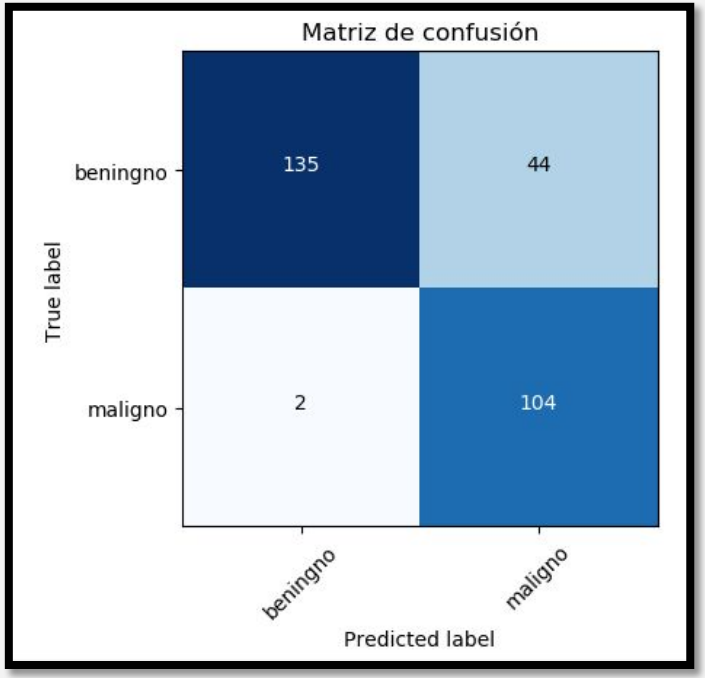

Métricas - Precision

$$\textbf{Precision} = \frac{TP}{(TP+FP)}$$

Prec = 104 / (104+44)= **0,70**

La **precisión** nos dice cuántos ítems reconocidos son realmente relevantes

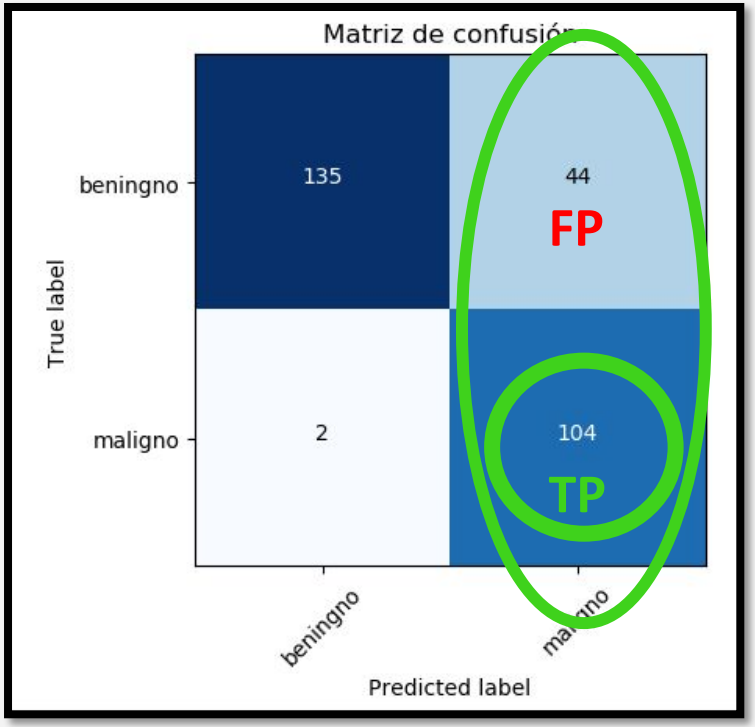

Métricas - Recall

$$\textbf{Recall} = \frac{TP}{(TP+FN)}$$

Rec = 104 / (104+2)= **0,98**

El **recall** nos dice cuántos ítems relevantes fueron realmente seleccionados

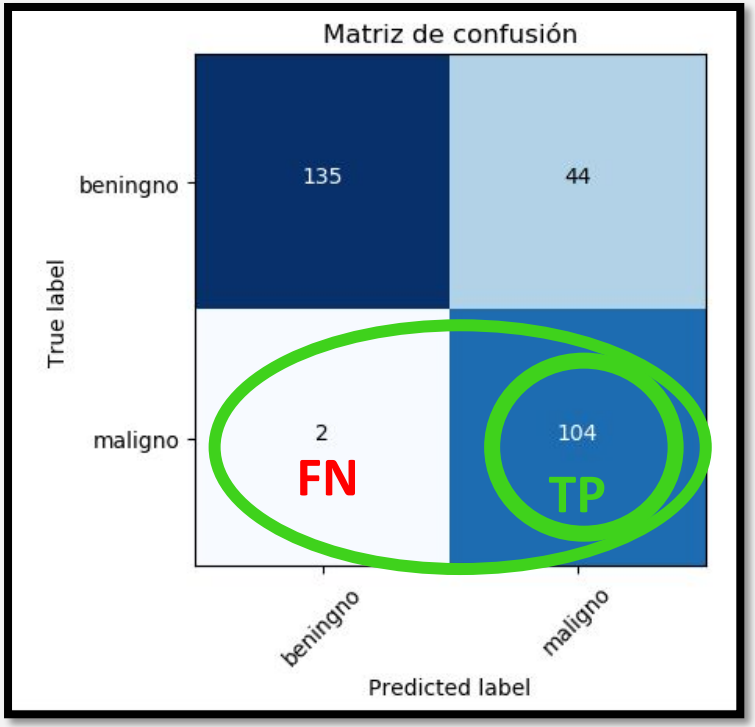

Métricas - Resumen

Acc = 0,84

Prec = 0,70

Rec = 0,98

- El Acc. nos muestra cómo se comporta el modelo teniendo en cuenta tanto los TP como los TN.
- El Prec. Y Rec. solo tienen en cuenta los TP.
- En clasificación binaria generalmente nos va a interesar más el Prec. Y Rec.

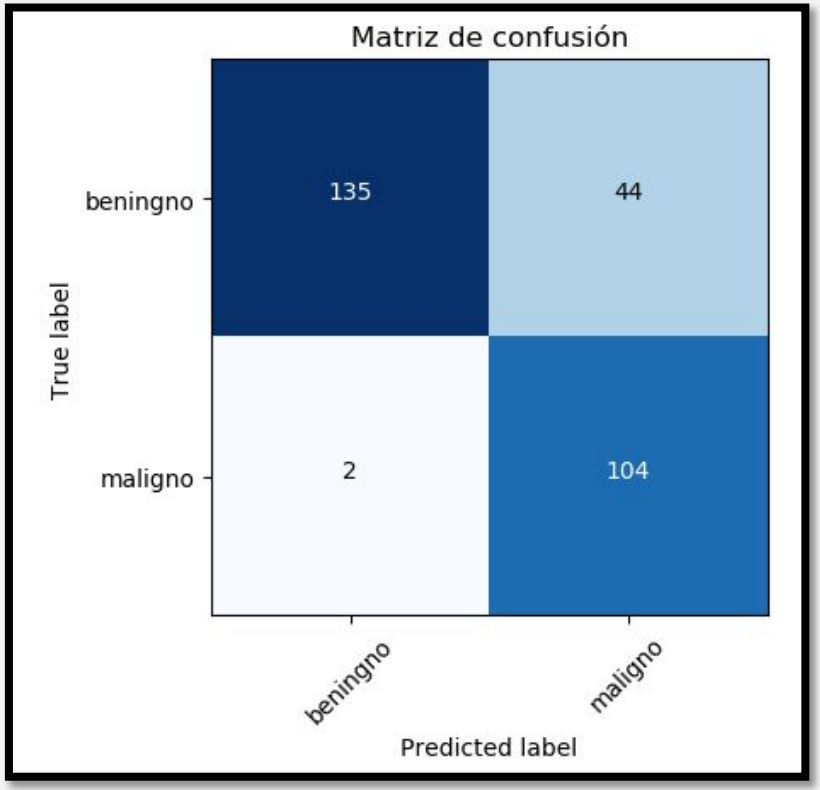

Métricas – F-measure

Para encontrar un balance entre estas métricas, suele utilizarse la media armónica, también conocida como *f-measure* (o *F1-score*):

$$f - measure = 2 \times \frac{precision \times recall}{precision + recall}$$

Acc = 0,84

Prec = 0,70

Rec = 0,98

F-measure = 0,82

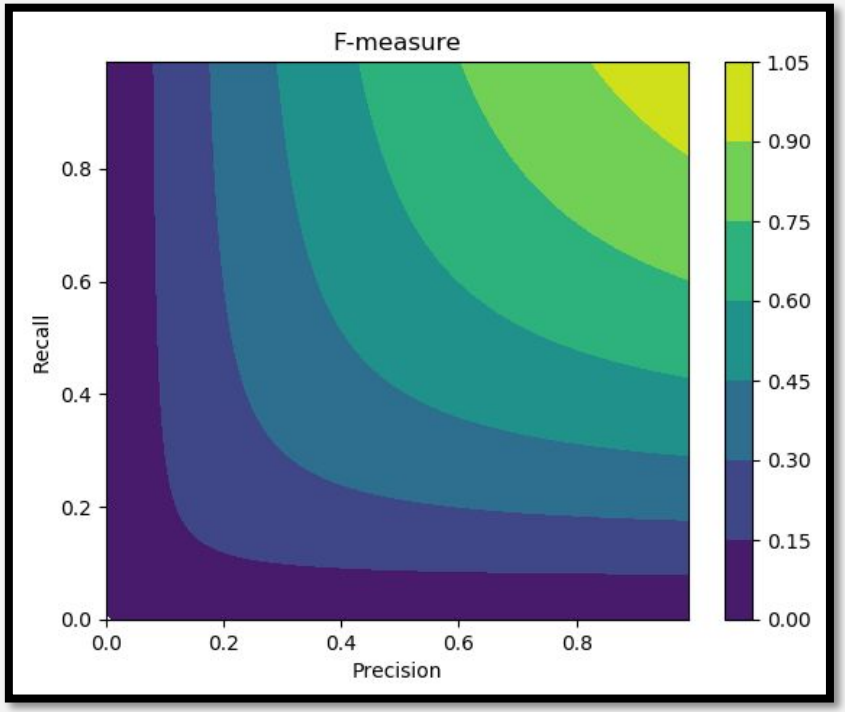

Ejemplos métricas – Dataset desbalanceado

Acc = 0,98

Prec = 0

Rec = 0

F-measure = 0

En este caso el *dataset* está muy desbalanceado (una clase es mayoritaria), lo que ocasiona que el modelo “aprenda” a decir siempre lo mismo.

Recordar que el modelo minimiza el error medio de todos los ejemplos.

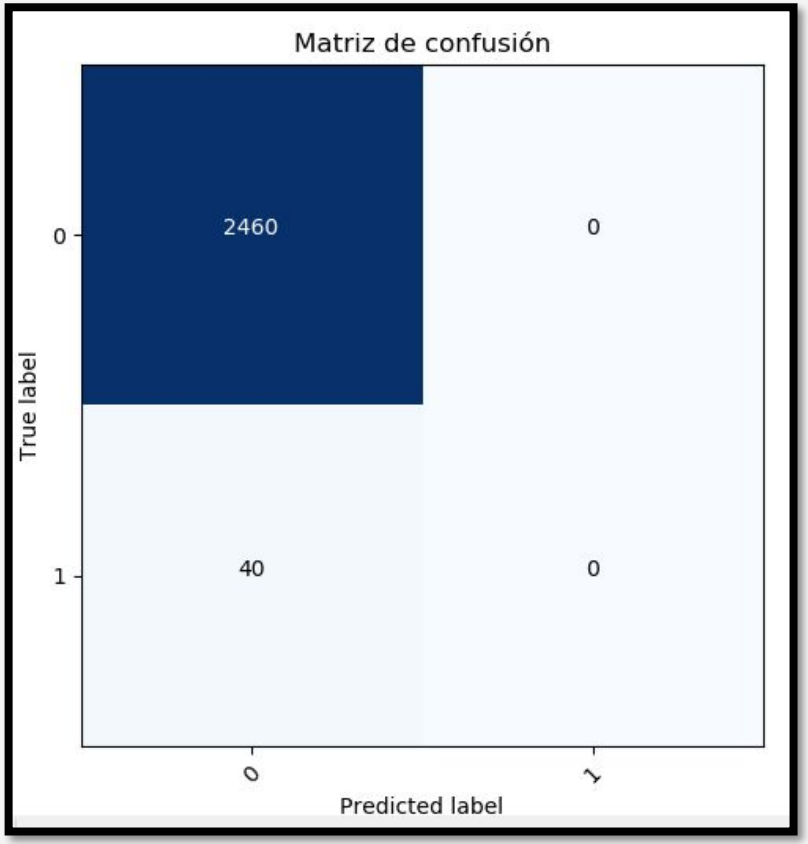

Dataset desbalanceado

Tenemos dos modos de solucionar el problema del desbalance de clases:

- Uno sería implementar nuestra propia función de error para que tenga en cuenta otra métrica.
- Otro es con el parámetro *class_weight* al momento de entrenar el modelo. Este parámetro es un diccionario que indica el peso que se le dará a cada clase dentro de la función de error durante el entrenamiento.

```
Test    Accuracy: 0.99
       Precision: 1.00
          Recall: 0.76
       f-measure: 0.87
```

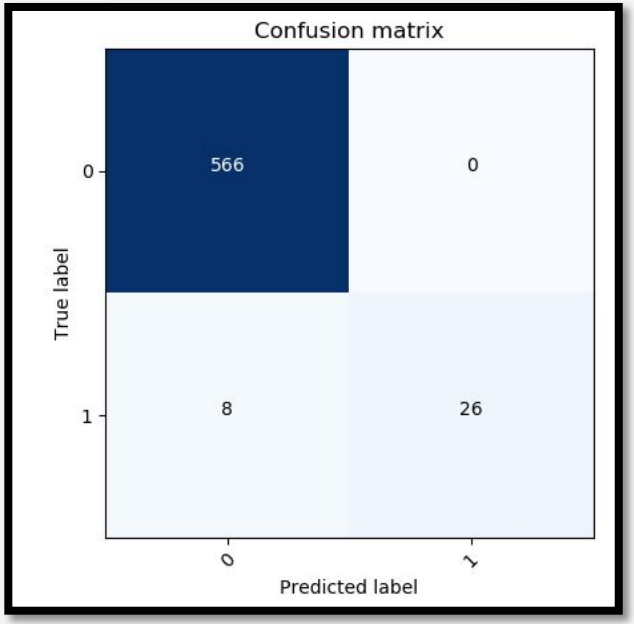

Dataset desbalanceado

```
Test    Accuracy: 0.98
        Precision: 0.80
           Recall: 0.93
         f-measure: 0.86
```

```
model.fit(    X_train, Y_train,
              epochs= EPOCAS,
              batch_size= LOTE,
              class_weight= {0:0.3, 1:0.7} )
```

A medida que inclinamos el peso hacia una u otra clase, aumentará el Recall y disminuirá el Precision, o viceversa.

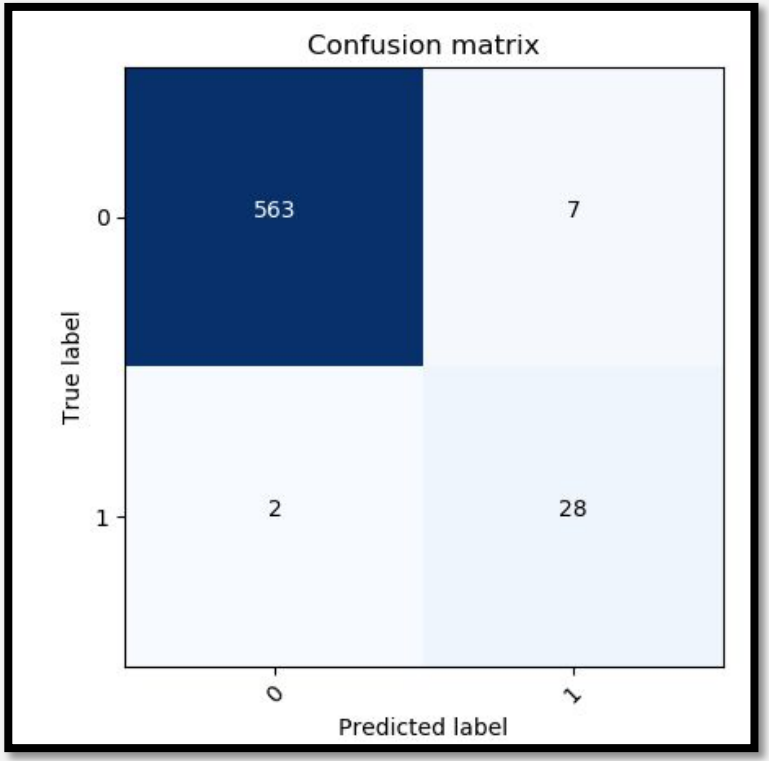

Dataset desbalanceado

```
Test    Accuracy: 0.99
        Precision: 1.00
           Recall: 0.76
         f-measure: 0.87
```

```
class_weight= {0:0.5, 1:0.5}
```

```
Test    Accuracy: 0.98
        Precision: 0.80
           Recall: 0.93
         f-measure: 0.86
```

```
class_weight= {0:0.3, 1:0.7}
```

```
Test    Accuracy: 0.95
        Precision: 0.60
           Recall: 0.95
         f-measure: 0.73
```

```
class_weight= {0:0.05, 1:0.95}
```

Curvas ROC

Las curvas ROC (Receiver Operating Characteristic) nos muestran cómo se comporta un modelo binario al cambiar el umbral de detección.

True Positive Rate = Sensitividad = Recall= TP/(TP+FN)

False Positive Rate= 1 - Especificidad= 1- TN/(FP+TN)

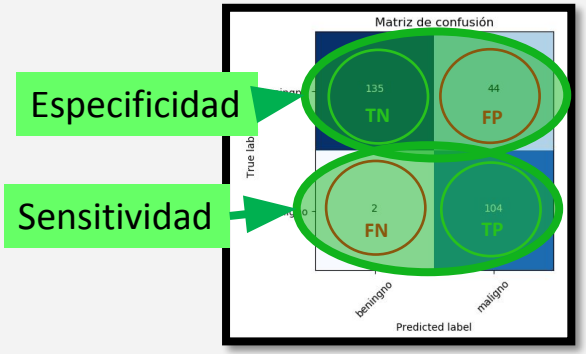

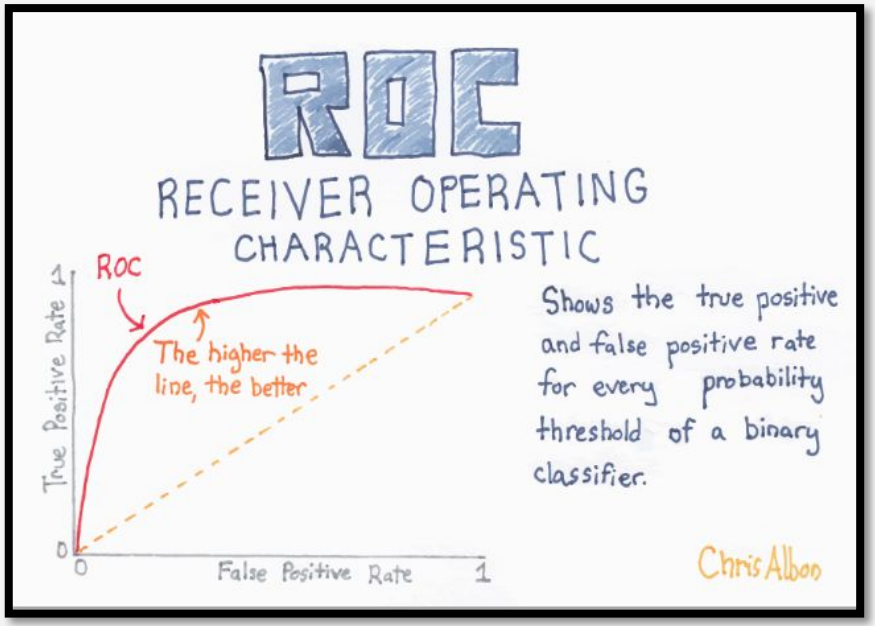

Curvas Precision-Recall

Las curvas **Precision-Recall** se computan de igual modo que las curvas ROC pero grafican el funcionamiento del modelo para estas métricas.

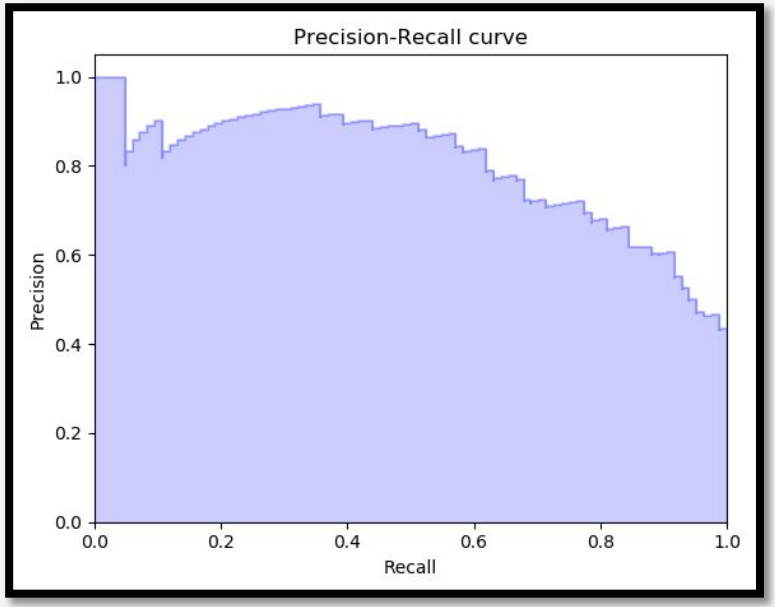

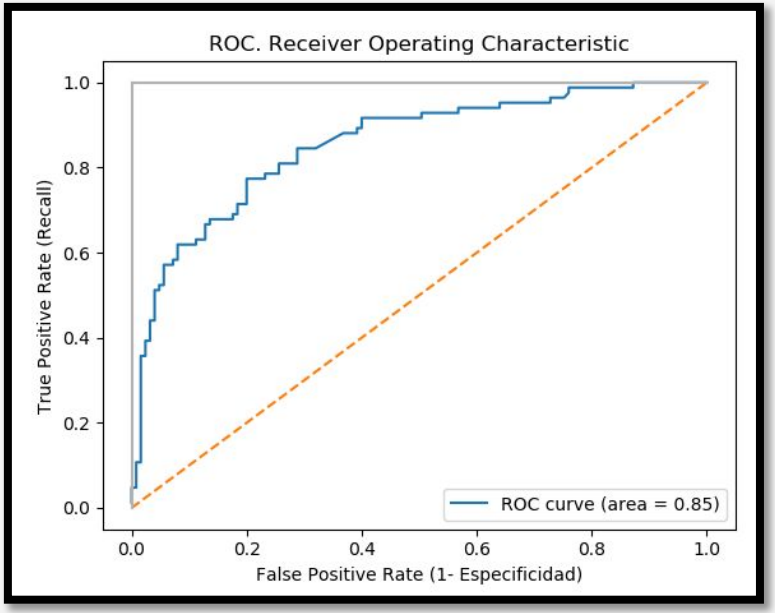


```
AAPutils.plot_ROC_curve(model, x, y)
```